

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«Южно-Уральский государственный университет (национальный исследовательский университет)»
Институт естественных и точных наук
Кафедра прикладной математики и программирования

Отчет по лабораторной работе № 4
Архитектуры рекуррентных нейронных сетей

по дисциплине

«Современные нейросетевые технологии»

ЮУрГУ - 01.04.02. 2025. 306/010. Р

Руководитель, преподаватель

_____/ Д.М. Кичеев /

« ____ » июня 2025 г.

Автор

студент группы ИЕТН - ЕТ-122

_____/ О.В. Ростова /

« ____ » июня 2025 г.

Челябинск 2025

Цель настоящей работы состоит в том, чтобы построить архитектуру рекуррентных нейронных сетей, которые позволяют решить практическую задачу с высокими показателями качества.

Выполнение практической работы предполагает решение следующих **задач**:

1. Разработка нескольких архитектур рекуррентных нейронных сетей.
2. Обучение разработанных глубоких моделей.
3. Тестирование обученных глубоких моделей.
4. Сравнение полученных результатов с результатами 3 лабораторной работы.
5. Публикация разработанных программ/скриптов в личном репозитории на GitHub.
6. Подготовка отчета, содержащего минимальный объем информации по каждому этапу выполнения работы.

Выполнение лабораторной работы осуществлено мною в Google Colab на языке программирования Python. Результаты и отчет размещены в личном профиле на GitHub, ссылка: <https://github.com/Olga-1911/Recurrent-Neural-Network-Architectures>.

В процессе выполнения лабораторной работы, мною были выполнены следующие шаги:

1. Для выполнения лабораторной работы № 4 я выбрала **задачу классификации текстов**, так как это стандартная задача для RNN.

Для решения задачи классификации текстов был выбран набор данных **IMDB** (Internet Movie Database) Dataset.

Характеристики набора данных IMDB:

- содержит 50 000 рецензий фильмов, разделённых на обучающую (25 000 рецензий) и тестовую (25 000 рецензий) выборки;
- каждая рецензия аннотирована метками тональности (positive/negative);

- набор данных является сбалансированным, что позволяет избежать смещения модели в сторону одного класса.

Перед обучением моделей данные подверглись предобработке (токенизации, приведение последовательностей к фиксированной длине, формированию словаря).

2. Произведена **разработка архитектур моделей**.

В рамках лабораторной работы были разработаны следующие архитектуры рекуррентных нейронных сетей:

- **SimpleRNN**: базовая RNN, которая последовательно обрабатывает элементы последовательности и учитывает предшествующий контекст. Несмотря на простоту, проявляет ограничения при моделировании длительных зависимостей.

- **LSTM** (Long Short-Term Memory): расширенный вариант RNN, разработанный для борьбы с проблемой затухающего градиента благодаря введению механизмов забывания и запоминания (input, output, forget ворота). Эта модель лучше захватывает долгосрочные зависимости в тексте.

- **GRU** (Gated Recurrent Unit): упрощённая версия LSTM с меньшим количеством параметров, что приводит к более быстрой и эффективной работе при сохранении высокой производительности.

Каждая модель была создана и оптимизирована для решения задачи анализа тональности. Обучение проводилось с использованием стандартных оптимизаторов и показателей (accuracy, F1-score).

3. Реализовано **обучение и тестирование моделей**.

Обучение моделей осуществлялось в Google Colab с использованием языка Python. Для каждой из моделей (SimpleRNN, LSTM, GRU) был проведён процесс обучения и последующей валидации на тестовой выборке. В качестве метрик использовались Accuracy и F1-score.

Сводная таблица результатов (на наборе данных IMDB) представлена в таблице:

Модель	Accuracy	F1-score
SimpleRNN	0.7690	0.7679
LSTM	0.8676	0.8713
GRU	0.8767	0.8805

4. Сравним с результатами лабораторной работы № 3.

В лабораторной работе № 3 рассматривались следующие модели на наборе данных CIFAR-10:

- **FCNN_2_layers**: Время обучения: 1056.31 сек, Точность: 0.4307
- **FCNN_3_layers**: Время обучения: 861.18 сек, Точность: 0.4796
- **CNN**: Время обучения: 14881.19 сек, Точность: 0.8405

Лабораторная работа № 3 ориентирована на задачу классификации изображений (CIFAR-10), а лабораторная работа № 4 – на анализ тональности текстов (IMDB).

Для обработки изображений более подходящей оказалась сверточная нейросеть (CNN), тогда как для последовательных данных (тексты) эффективнее работают реверрентные архитектуры.

Модели, обучающиеся на изображениях (особенно CNN), требуют значительно большего **времени для обучения** по сравнению с моделями для анализа текста.

В случае текстовых данных **время обучения** моделей RNN оказалось приемлемым и зависело от сложности структуры (SimpleRNN – быстрее, но менее точная; LSTM и GRU – немного медленнее, но обеспечивают существенное улучшение показателей).

Модели с использованием RNN (LSTM и GRU) продемонстрировали высокую точность (87% и почти 88% соответственно) и превосходно справились с задачей анализа тональности, что значительно превышает показатели простых FCNN, представленных в лабораторной работе № 3.

GRU, благодаря упрощённой архитектуре, показала наилучшие результаты среди рассмотренных RNN-моделей.

5. По результатам выполнения работы можно сделать следующие выводы:

5.1. Соответствие типа архитектуры задаче.

Выбор архитектуры нейронной сети напрямую зависит от типа данных и задачи. Для анализа тональности текстов архитектуры с рекуррентными блоками (LSTM и GRU) справляются значительно лучше, чем базовая SimpleRNN, что обусловлено наличием механизмов управления памятью.

5.2. Преимущества сложных RNN-моделей.

Модели LSTM и GRU продемонстрировали существенно более высокие показатели (Accuracy и F1-score) по сравнению с SimpleRNN. GRU показала небольшое превосходство, что свидетельствует о том, что упрощённая архитектура может быть эффективной при снижении вычислительной сложности.

5.3. Сравнение с предыдущей работой.

Сравнение результатов с лабораторной работой № 3 показывает, что для решения задач классификации текстов использование RNN-моделей позволяет достигнуть значительно более высоких показателей качества, чем модели на базе FCNN, применяемые для обработки изображений. Несмотря на большее время обучения CNN в лабораторной работе № 3, их высокая точность обусловлена особенностями обработки двумерных данных, в то время как рекуррентные сети идеально подходят для одномерных последовательностей.

5.4. Адаптация модели под задачу.

Для достижения оптимальных результатов важно подбирать архитектуру, способную адекватно моделировать специфические зависимости в данных, будь то пространственные структуры изображений или временные зависимости в текстах.

Заключение

Выполненная лабораторная работа демонстрирует, что рекуррентные нейронные сети (LSTM и GRU) являются мощным инструментом для

решения задач анализа тональности текстов. Сравнение с предыдущими подходами показывает, что для разных типов данных необходимо применять специализированные архитектуры. Разработанные модели успешно обучены и протестированы, а результаты экспериментов опубликованы в личном репозитории.